１ 研究目的、研究方法など

本研究計画調書は「小区分」の審査区分で審査される。記述に当たっては、「科学研究費助成事業における審査及び評価に関する規程」（公募要領参照）を参考にすること。
本研究の目的と方法などについて、５頁以内で記述すること。
冒頭にその概要を簡潔にまとめて記述し、本文には、(1)本研究の学術的背景や本研究の着想に至った経緯、研究課題の核心をなす学術的「問い」、(2)本研究の目的および学術的独自性と創造性、(3)関連分野の研究動向と本研究の位置づけ、(4)本研究で何をどのように、どこまで明らかにしようとするのか、(5)本研究の目的を達成するための準備状況、(6)本研究がどのような国際性（将来的に世界の研究をけん引する、協同を通じて世界の研究の発展に貢献する、我が国独自の研究としての高い価値を創出する等）を有するかについて具体的かつ明確に記述すること。
本研究を研究分担者とともに行う場合は、研究代表者、研究分担者の具体的な役割を記述すること。

（概要）

危機言語の記録保存は消滅までの時間との戦いである。本研究の目的は、日琉諸語を研究する記述言語学者と理論言語学者、低資源言語を対象に研究を進める自然言語処理研究者とが協働して、言語記録保存の取り組みを高速化するシステムを提案することである。具体的には、記録保存において最も手間のかかる**自然談話データの形態素解析・形態素注釈（グロス付与）の自動化**を実装する（図１参照）。

input	pred_morphs	pred_gloss
mmja	mmja	DSC
misinnasii	misin + nas + i + i	ミシン + CVLZ + THM + SEQ
katti	ka + tti	***買う** + QUOT
uibadu	u + i + ba + du	***いる** + CNF + CSL + FOC
mmja	mmja	DSC
kuusjuunu	kuusjuu + nu	空襲 + ***GEN**
sugu	sugu	DSC
baribaritti	baribari + tti	ONM + QUOT
assiba	ass + i + ba	言う + THM + CSL

図 1: /mmja misinnasii katti uibadu mmja kuusjuunu sugu baribaritti assiba/「もう、ミシンしていたら空襲がバリバリとやってきて」という未注釈データに対し、自動解析システムを通して得られた注釈テクスト（pred_morphs と pred_gloss はシステムが予測する形態素分割とグロス）。太字アスタリスク部分が誤り（下地 印刷中）。

個々の研究者の実態に即して、少量データでも安定するモデル（BiLSTM + CRF+ MTL、p. 4 で詳述）を提案する。Python スクリプトとして公開すると同時に、Web 上で動くインテラクティブ HTML ツールも実装する。

（本文）

学術的背景

日琉諸語は総じて消滅の危機にある。21 世紀に入り、記述文法書・辞書・談話資料のいわゆる「３点セット」の作成が学界全体の課題となっており、例えば国立国語研究所の一連の大規模共同研究「消滅危機方言の調査・保存のための総合的研究」「日本の消滅危機言語・方言の記録とドキュメンテーションの作成」「消滅危機言語の保存研究」では３点セットの整備が強調されてきた。

３点セットのうち、琉球諸語を中心に記述文法の作成が隆盛を極めており、本土方言においても少しずつ成果が出始めている（下地 2021）。辞書については研究者だけでなく話者による出版も盛んであり、オンライン化も進みつつある（カルリノ 2022）。一方、談話資料については、各研究者の公開がなかなか進まない状態が続いている。一般に、消滅危機言語の談話資料には厳しい要求水準があり、一貫した語境界の認定と語内部の徹底した形態素注釈（グロスづけ）が必須である。これは複行注釈テキスト（Interlinear Glossed Text; IGT）と呼ばれる。図２は宮古語伊良部島方言の IGT の例である。

mmja ai=nu zidai=tii=ja kuu-n=pazɨ=tii umu-i-ur.
DSC そう=GEN 時代=QUOT=TOP 来る-NEG=CJC=QUOT 思う-THM-PROG
「もうあんな時代は来ないだろうと思っている。」

図 2: IGT 標準構成による宮古語伊良部島方言の談話の例。1 行目は語（文節）で区切った音素表記のテクスト、2 行目は形態素ごとにグロスをつけたもの、3 行目に全文訳。

【1　研究目的、研究方法など（つづき）】

方言研究においてよく知られる既存の談話資料（『全国方言談話資料』（NHK 編）や国立国語研究所編『日本のふるさとことば集成』など）は残念ながら IGT 標準を満たしていない。図 3 に示すように、典型的には文節単位の訳づけという簡易な形式をとる。これは 2025 年現在でも事実上の標準になっている（文化庁「各地方言収集緊急調査」音声資料公開ページなど）。

mmja	'a'ino	zida'i	tiʀ'ja	kɔʀN	paʒ	tiʀ	'omo'i'jor
もう	あんな	時代	は	来ない	はず	と	思っている。

図 3: 『全国方言資料』における宮古語伊良部島方言の談話の例（図 2 と同一の文）

図 3 の注釈法は、IGT 標準を満たした図 2 と比べると情報量の損失が目立つ。例えば、'a'ino「あんな」は、正確には様態副詞/ai/に属格/nu/が接続した構造をしているが（図 2 参照）、それは図 3 からはわからない。日本語の連体詞「あんな」と構造が大きく異なる点が覆い隠されている。注釈情報の貧弱さによる情報量の損失は、言語記録保存において致命的である。だからこそ、IGT 標準という厳しい要求水準がある。さらに、自然言語処理における多数の事例で報告されているように、典型的に少量データとなる危機言語の談話データを機械翻訳などに応用する際、注釈が IGT 標準を満たしているかどうかが決め手になる（McMillan-Major 2020）。

IGT 標準を満たすためには、収集した録音データを音素表記で正確に書き起こし、韻律情報などをもとに一貫した基準で語に分割し、さらに形態素に分割し、文法形態素の全ての機能を把握し、適切なグロスを付与する必要がある。調査の初期には、まさに言語記述を進めながらの一進一退の作業となるが、注釈に関する方針が安定してくれば、あとは手間のかかる単純作業（形態素分割とグロスづけ）を延々とこなしていくこととなる。この手間は、限られた時間で、しかも典型的には一人で記述を進めるフィールドワーカーには大変なコストとなる。

結果的に、注釈をつける知識はあるにも関わらず、IGT 標準を満たす労力が莫大なため、注釈の済んでいないデータだけが山のように積み上がり、談話資料としての刊行がいつまでもままならないという状況が生じやすいのである。しかも、「いつか」と思っていても、消滅の危機が迫るというタイムリミットがあり、見切り発車的に、IGT 標準を満たさない（記録保存資料として適切でない）談話資料が刊行され続けるという現実がある。

本研究の問い

現状を踏まえると、消滅の危機にある日琉諸語の談話資料の整備を促進していく上で問うべき問題は、**消滅まで時間のない中で、個々のフィールドワーカーが IGT 標準の談話資料を作成する労力をいかにして削減するか**という点に尽きる。本研究は、この問題に対する解決策を提案する。

本研究の目的

本研究は、上記の問題を解決する策として、自然言語処理技術の援用を提案する。具体的には、フィールドワーカーが手動で注釈づけを行った少量の IGT データ（例えば録音 1-2 時間相当の文字化テクスト）をもとにして、これを機械学習の教師データとし、その結果得られる学習モデルによって自動で注釈をつけ、大量の IGT 標準データを得る仕組みを整える（図 4）。

今、あるフィールドワーカーの手元に、IGT 標準で注釈を済ませた 1 時間分の書き起こし談話データがあり、未注釈の書き起こしデータ（音素表記で文節に区切った方言談話とその全文訳のペア）が 10 時間あるとする（これはある程度経験を積んだフィールドワーカーには決して珍しくない状況である）。図 4 に示すように、フィールドワーカーは機械学習用に、1 時間の質の高い IGT 標準の注釈データを準備する必要はあるが、逆に言えばそれがあれば、残りの 10 時間分のデータは瞬時に注釈されることになる。もちろん、出来上がった注釈のチェックと微修正は必要になるが、全て人力で行う労力とは比較にならない。

【1　研究目的、研究方法など（つづき）】

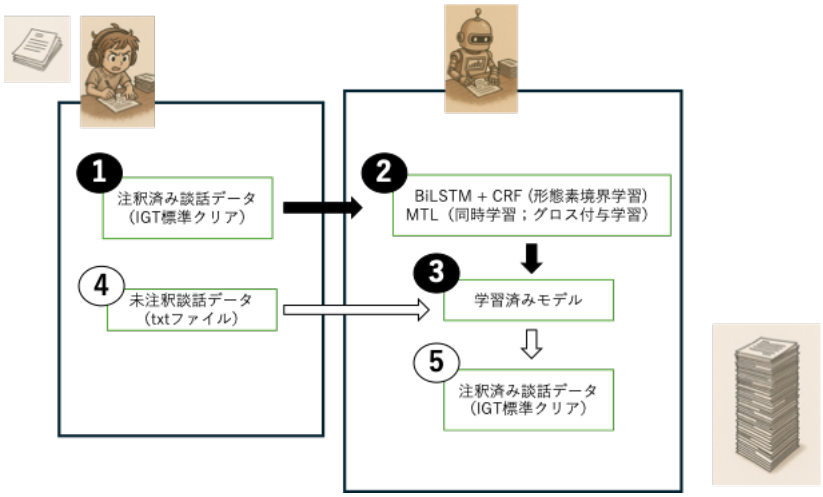

図 4: 本研究の概略。少量の書き起こし談話データ（IGT 標準）を準備し（1）、機械学習させ（2）、出来上がったモデル（3）が未注釈談話データを読み込む（4）。モデルはこれを IGT 標準の注釈データとして吐き出す（5）。黒丸の工程はモデル構築まで、白丸の工程はモデル構築後。

本研究の独自性と創造性

[1] 機械学習による IGT 標準の達成

本研究は、自然言語処理の技術を援用して IGT 標準を満たす談話資料の作成を促すという点で、これまでの方言研究の談話資料作成のあり方と一線を画す。図 3 の既存の談話資料に見たように、時間がない中で IGT 標準を「諦める」という従来の日琉諸語研究のやり方を消極的対処法とすれば、人的コストが最もかかる部分（形態素解析とグロスづけ）を自動化するという本研究の対処法は積極的対処法であり、ここに本研究の最も特筆すべき独創性がある。

[2] 言語学者と自然言語処理研究者の協働

本研究の第二の独創的な点は、経験豊富なフィールド言語学者と形態論の専門家、そして自然言語処理の実装面の専門家が協働で注釈システムを開発する点にある。自然言語処理技術者だけでは、言語事実の正確な分析よりも実装面の効率性に偏る可能性がある。本研究は、それぞれの言語の専門家が、それぞれの言語に適した語境界の設定、形態素境界の設定を行い、それを教師データとすることで、言語学的にみて正確な注釈づけを達成する。

関連分野の研究動向と本研究の位置付け

データが少なくコーパスも整備されていない**低資源言語**の限られたデータを活用する方法論が近年議論され始めており、グロスづけの自動化もその 1 つである（Palmer et al. 2009, Moeller and Hulden 2018, McMillan-Major 2020, Ginn et al. 2023, Elsner and Liu 2025）。日琉諸語はその議論においてこれまで取り上げられておらず、本研究がその最初の研究となる。

なお、本研究と密接に関連する分野として自動翻訳分野が挙げられる。これは、方言テキストと（例えば）標準語テキスト間の翻訳を自動化することを目指す分野である。すでに述べてきたように、本研究では、語（文節）で区切られた音素表記の原文テキスト（未注釈データ）とその全文訳（標準語テキスト）が手元にあるという状況を想定しており、**自動翻訳を問題にしているのではない**。あくまで言語学的に正確な原文テキストの形態素解析とグロス付与を自動で行うことを目指している（図 1 参照）。ただし、本研究の成果（IGT 標準を満たす多数の方言談話データ）が揃うことで、低資源言語の自動翻訳の問題であるデータ量の少なさを注釈情報の質で補い、より正確な翻訳が可能になると予測される（Ginn et al. 2024）。

【1　研究目的、研究方法など（つづき）】

何をどこまで明らかにするか

[1] 機械学習のモデル

本研究では、日琉諸語のフィールドワーカーにありうる以下の 2 つのシナリオを想定する。まず、**質依存シナリオ**がある。経験豊かなフィールドワーカーが、当該言語の構造を十分に把握している場合である。この場合、IGT 標準で書き起こした少量データに強固な一貫性があり、未知の文法形態素も少なく、質の高い教師データが得られ、少量データでも安定する機械学習モデルを実装できる。もう 1 つのシナリオは**量依存シナリオ**である。当該言語を専門とする研究者が存在せず、IGT 標準の教師データを用意することがそもそも難しいような場合である。このシナリオでは、IGT 標準をクリアしていなくても、とにかく大量のデータを機械学習（Transformer 系）の入力に用いて、そのデータの量に「モノを言わせて」質の高い学習を行うモデルを組む必要がある。

本研究では質依存シナリオを想定する。本研究は「注釈づけの知識があるのに時間がない」状況を解決することを目的としているためである。

[2] デモ言語の選定

本研究では、日琉両方の言語に適用できる機械学習モデルを提案することを目指している。そこで、本研究では本土方言から鹿児島県串木野方言を、琉球諸語から宮古語伊良部島方言をデモ言語として選定し、これらに集中してモデルを構築していく。2 言語とも、専門のフィールド言語学者がおり（代表者の下地と分担者の黒木氏）、質の高い IGT 標準の教師データを用意できる。

本研究の準備状況

[1] 機械学習システムの試験運用

本研究の「質依存シナリオ」の実現可能性を実証するため、システム試験運用と性能評価を終えている（下地 印刷中）。システムは BiLSTM + CRF（Hochreiter and Schmidhuber 1997）を用いた。まず、文字列の「形態素境界らしさ」を BiLSTM で前後双方向から捉え、さらに CRF で出力ラベル（BIO ラベル）の B(genning)/I(nside) の連続性（ありえない並びを排除）を制約して一貫した境界列を出すことで、BiLSTM の境界認識を強化（統制）する。続いて、上記で切り出された文字列（スパン）に対して、BiLSTM の隠れ状態をスパン単位で集約し、まず品詞を予測、それを条件（ヒント）にグロスを予測する。品詞は IGT 標準に含まれない注釈情報だが、これがあることでグロス付与の精度も高まることが知られている（Moeller and Hulden 2018）。

試験運用で用いた談話データは伊良部島方言の談話 30 分（289 文、1969 語）、2738 形態素である。教師用 (gold、259 文) と評価用（heldout、30 文）にわけ、前者をモデル構築（学習）に使い、後者 30 文（モデルにとって未知のデータ）をモデル評価用にした。30 文の精度評価のサマリーを表 1 に示す（詳細は下地印刷中参照）[1]。SegExact token は語単位の形態素分割の精度（97.2%）SegExact sentence は文単位の形態素分割の精度（86.7%）、Gloss token (seg-exact) は、正しい形態素分割がなされた形態素トークンで、そのグロス付与の精度は 84.7%、品詞ラベル付与の精度は 75.4%である。この性能は、本研究が扱う質依存シナリオとモデル設定の点で近い Lezgi 語の研究（Moeller and Hulden 2018）の性能に比肩するものである（グロス付与の F1 値 0.9 から 0.76）。このように、本研究の実現可能性が高いことはすでに試験段階で実証されている。

表 1: 試験運用モデルの性能評価（下地 印刷中）

Metric	Value
SegExact (token)	140/144 = 97.2%
SegExact (sent)	26/30 = 86.7%
Gloss tokens (seg-exact)	n=295
Gloss Acc	250/295 = 84.7%
Gloss F1 (macro/weighted)	88.2/84.8
POS tokens (seg-exact)	n = 297
POS Acc	224/297 = 75.4%
POS F1 (macro/weighted)	61.9/73.5

[1] 30 文の全リストとモデルの予測、正解（gold）の比較リスト（csv 形式）は Github のリポジトリで閲覧できる（`https://github.com/MichinoriShimoji/autoglossing/blob/main/heldout_preds_20250827_135331.csv`）。

【1　研究目的、研究方法など（つづき）】

[2] IGT 標準に必要な言語学的分析

IGT 標準を満たすためには、日琉諸語の形態構造に即した語境界の認定方針と形態分析法、さらに各地域言語の実態に則したグロスを付与する必要がある。前者について、本研究は日琉諸語のフィールド言語学者（下地、黒木氏、宮岡氏、高城氏）と形態理論の専門家（田川氏、ジスク氏）が揃っており、すでにそれぞれが豊富な経験と知見を有している。後者について、本研究メンバーのうち 3 人（ジスク氏、黒木氏、下地）が過去に行った共同研究（基盤 B「多言語による日本語学用語辞典および日琉諸語の用例に対するグロス規範の作成」19H01265）が、まさに日琉諸語のグロス標準化に関するものであり、本研究でもその知見をそのまま利用可能である。

本研究の国際性

本研究の国際性は以下の 2 点で評価できる。まず、本研究が扱う質依存シナリオは、危機言語という「超」低資源言語の研究環境において極めて現実的でありながらも、その現実を見据えてモデルを組み立てる先行研究は実は非常に少ない。上記の Moeller and Hulden (2018) はその数少ない例であり、p. 3 で挙げた研究の多くはむしろ量依存シナリオ寄りである。本研究の成果は、この点で、危機言語の実態に即した研究として国際的にも注目されることになるであろう。

次に、本研究の成果は、注釈済み談話データによる形態統語構造の通言語比較を目指す、自然言語処理分野における大型国際プロジェクトである Universal Dependencies プロジェクト（UD; Marine-Catherine de Marneffe et al. 2021）への日本側の貢献を促すことになるであろう。本研究で生み出される自動注釈済みデータは、語境界情報、形態素グロス情報、そして品詞情報が揃うが、品詞情報は IGT 標準を超えた、ある意味で「贅沢」な追加情報となる。そしてこれこそ、UD における注釈情報の核となる。UD は、通言語的に規定された品詞タグ（UPOS）と、それら同士の関係（DepRel）情報によって、さまざまな言語の構造を依存関係で表現し、言語間比較を可能にする。日本語標準語の UD（UDJ）はすでに公開されているが、残念ながらそのガラパゴス的な、すなわち学校文法由来の形態アノテーションと品詞ラベリングにより、通言語比較において重大な問題があることが度々指摘されてきた（Taguchi and Chiang 2023）。本研究では、IGT 標準に即した厳密な語境界認定、形態素グロス、品詞認定を行うため、結果的に UD が求める世界標準に合致する注釈を提供できる。こうして、本研究をきっかけに、日琉諸語としては初の、世界標準に完全に合致した UD ツリーバンク登録が可能になる。

引用文献

Elsner, Micha and David Liu (2025) "Prompt and circumstance: A word-by-word LLM prompting approach to interlinear glossing for low-resource languages"/**Ginn, Michael, Sarah Moeller, Alexis Palmer, Anna Stacey, Garrett Nicolai, Mans Hulden, and Miikka Silfverberg (2023)** "Findings of the SIGMORPHON 2023 Shared Task on Interlinear Glossing," in Nicolai, Garrett, Eleanor Chodroff, Frederic Mailhot, and Cagr Coltekin eds. *Proceedings of the 20th SIGMORPHON workshop on Computational Research in Phonetics, Phonology, and Morphology*, pp. 186—201, Toronto, Canada: Association for Computational Linguistics/**Hochreiter, Sepp and Jürgen Schmidhuber (1997)** "Long Short-Term Memory," *Neural Comput.*, Vol. 9, No. 8, p. 1735–1780, November./**Marie-Catherine de Marneffe, Christopher D. Manning, Joakim Nivre, and Daniel Zeman. (2021)** Universal Dependencies. Computational Linguistics, 47(2): 255–308/ **McMillan-Major, Angelina (2020)** "Automating Gloss Generation in Interlinear Glossed Text," in Et- tinger, Allyson, Gaja Jarosz, and Joe Pater eds. *Proceedings of the Society for Computation in Linguistics 2020*, pp. 355—366, New York, New York: Association for Computational Linguistics./**Moeller, Sarah and Mans Hulden (2018)** "Automatic Glossing in a Low-Resource Setting for Lan- guage Documentation," in Klavans, Judith L. ed. *Proceedings of the Workshop on Computational Modeling of Polysynthetic Languages*, pp. 84—93, Santa Fe, New Mexico, USA: Association for Computational Linguistics./**Palmer, Alexis, Taesun Moon and Jason Baldridge (2009)** "Evaluating Automation Strate- gies in Language Documentation," in Ringger, Eric, Robbie Haertel, and Katrin Tomanek eds. *Proceedings of the NAACL HLT 2009 Workshop on Active Learning for Natural Language Pro- cessing*, pp. 36—44, Boulder, Colorado: Association for Computational Linguistics./**カルリノサルバトーレ (2022)** 「「日琉諸語オンライン辞書」の紹介」『日本語の研究』 18 (3): 52-59./**下地理則 (2021)** 「グラマーライティング：方言の記述文法を書くガイド」『日本語文法』 21(2): 136–151. /**下地理則 (印刷中)** 「低資源言語におけるテキスト自動解析とグロス付けの自動化–伊良部島方言のケーススタディ」『琉球の方言』 49./**Taguchi, Chihiro and David Chiang (2023)** Introducing Morphology in Universal Dependencies Japanese. In Proceedings of the Sixth Workshop on Universal Dependencies (UDW, GURT/SyntaxFest 2023), pages 65–72, Washington, D.C..Association for Computational Linguistics.

２　応募者の研究遂行能力及び研究環境

応募者（研究代表者、研究分担者）の研究計画の実行可能性を示すため、(1) これまでの研究活動（主要な研究業績を含む）、(2) 研究環境（研究遂行に必要な研究施設・設備・研究資料等を含む）について２頁以内で記述すること。
「(1) これまでの研究活動」の記述には、研究計画に関連した国際的な取組（国際共同研究の実施歴や海外機関での研究歴等）がある場合には必要に応じてその内容を含めること。また、研究活動を中断していた期間がある場合にはその説明などを含めてもよい。

これまでの研究活動

本研究の遂行において要求される能力は以下の 3 つに集約されるが、本研究はそのいずれに関しても経験豊富な第一線の人材で臨む（括弧内は、最も強く関連する応募者の名前）。

1. 消滅危機言語としての日琉諸語を実際に記述し、記録保存している現場のフィールドワーカーとしての能力（→ **下地、黒木、宮岡、高城**）
2. 自然言語処理技術を操るプログラミングの知識と実装経験（→ **下地、宮川**）
3. 形態素分割・グロスラベルの標準化に関する知識と経験（→ **ジスク、宮岡、田川**）

1 **について**、本研究で扱う地域言語は宮古語伊良部島方言と鹿児島県串木野方言である。伊良部島方言は代表者の下地が担当する。下地は、当該言語の世界初の記述文法書を完成させ（業績番号 [1], [2]）、記述の経験は 20 年を超える。さらに消滅危機言語としての日琉諸語に関する入門書の執筆経験も豊富である（[3], [4], [5]）。分担者の黒木氏は西南部九州地域を専門とするフィールド言語学者であり、串木野方言のフィールド記述をもとにしたドキュメンテーション研究（[10]）の他、西南部九州地域を中心とした業績を多数有する（[11], [12]）。同じく分担者の宮岡大氏は東北から宮古島まで、全国各地のフィールド調査を行った経験を持ち、通時・共時形態論の記述のエキスパートである（[13], [14], [15]）。宮岡氏は黒木氏とともに串木野方言の調査を担当する。分担者の高城氏は、本研究の対象言語である串木野方言と同じく薩隅方言に属する鹿児島県内之浦/隼人町方言の記述の専門家であり（[17], [18]）、その経験を生かして、薩隅方言独自の形態論的問題やグロスに関する問題点に対応できる。高城氏も串木野方言調査を担当する。

2 **について**、代表者の下地は本研究の背景にある低資源言語の自動注釈に関する理論的問題点と実装面の十分な知識を備えており、本研究の土台となるシステム構築と試験運用に関して論文を発表している（[6]）。さらに、消滅危機方言を扱う言語学者向けに、自然言語処理を用いた Python スクリプト/ウェブアプリケーションを多数、発表している（[7], [8], [9]）。分担者の宮川氏は、日本のトップランクの自然言語処理研究者であり、低資源言語への自然言語処理技術の応用に関する研究を多数有する（[19], [20], [21]）。さらに、p. 5 で述べた UD に関する研究実績もある（[22]）など、まさに本研究を推進する上で欠かせない人材である。

3 **について**、本研究の中心となる IGT 標準に合致した自動注釈システムを実装するには、各方言データに対してどのような形態素分割法を用いるか、どのようなグロス略号を用いるか、そしてそれらの通方言的な標準化をどうするか、という難しい問題に取り組まなければならない。上記 1 で述べたように、本研究で扱う 2 言語については、下地と黒木氏のこれまでの記述に基づいた、安定した形態素分割法とグロス略号セットがすでに存在する。問題は、これらの間の統一的分析法（どのような形態素分割方針をとるか、語の認定方針、グロス略号の統一など）の整理を行い、さらにそれを他の日琉諸語にも適用可能なように標準化を行なっておく必要があるということである。分担者のジスク氏と宮岡氏はこの問題に取り組む上で最適の人材である。ジスク氏は、日琉諸語全般（さらには古典語まで）の形態素分割法とグロス略号の使用に関する標準化を目指した科研（基盤 B）を主導した経験があり（[23]）、3 の問題に直接関係する重要な論考を複数発表している（[24], [25]）。本研究では 3 の問題の統括を行う。宮岡氏はすでに上記 1 で述べたとおり、広範なフィールド経験を有するだけでなく、文化庁の談話資料の注釈づけ作業に携わった経験がある（[16]）。さらに、日琉諸語の記述研究で用いられる主なグロス略号を全て一覧にした「方言グロスリスト」（500 エントリー弱）を作成した経験も持つ（[30]）。分担者の田川氏は一般言語学・理論言語学（分散形態論）の専門家であり、本研究が扱う日本語系の言語構造をモデ

【2　応募者の研究遂行能力及び研究環境（つづき）】

ル化する形態理論に関して、数々の実績を有する（[26], [27], [28], [29]）。本研究は田川氏のアドバイスを積極的に取り入れ、構造主義と普遍主義のバランスの取れた注釈を目指す。

研究環境

本研究を推進する上で、特別に大型の施設は必要ない。自然言語処理的な計算を行う GPU は備品として予算を計上している。

引用文献リスト（業績番号順）

1 Shimoji, Michinori (2017) A Grammar of Irabu, a Southern Ryukyuan Language. Kyushu University Press.
2 下地理則 (2018)『南琉球宮古語伊良部島方言』くろしお出版
3 Heinrich, Patrick, Shinsho Miyara and Michinori Shimoji. eds. (2015) Handbook of the Ryukyuan Languages. Mouton de Gruyter
4 Shimoji, Michinori, and Thomas Pellard. eds. (2010) An Introduction to Ryukyuan Languages. ILCAA.
5 Shimoji, Michinori. ed. (2022) An Introduction to the Japonic Languages. Brill.
6 下地理則 (印刷中)「低資源言語におけるテキスト自動解析とグロス付けの自動化–伊良部島方言のケーススタディ」『琉球の方言』49号.
7 Shimoji, Michinori (2025) SearchGloss (DOI: 10.5281/zenodo.16419404) Version 1.0.
8 Shimoji, Michinori (2025) Eaftox (DOI: 10.57967/hf/6217)
9 Shimoji, Michinori (2025) InTEx: Interactive Text Gallery Generator (DOI: 10.5281/zenodo.16732543)
10 黒木邦彦・加藤幹治(2022)「少数方言の包括的記述を効率化する方法：文法書、辞書、談話集の作成・管理を言語注釈アプリELANで一括」日本方言研究会第114回研究発表会発表原稿集.
11 窪薗晴夫・森勇太・平塚雄亮・黒木邦彦(2015)『甑島里方言記述文法書』国立国語研究所
12 黒木邦彦(2019)「動詞語幹交替より紐解く九州方言のラ行五段化」窪薗晴夫・木部暢子・高木千恵編『鹿児島県甑島方言からみる文法の諸相』くろしお出版
13 宮岡大（2022）「動詞形態論」椎葉村方言語彙集編集委員会（編）『椎葉村方言語彙集』699–712. 宮崎県椎葉村・国立国語研究所
14 宮岡大（2025）「愛媛県大洲方言における動詞尊敬形の形態構造 —接頭辞/o-/による形式を中心に—」『日本語文法』25(1): 88–103.
15 Miyaoka, Hiroshi (2025) Cross-dialectal Formulations of the Occurrence Conditions of ragyō-godanka in Japanese Dialects, Focusing on Stem-final Vowels, the Stem Mora Count, and Suffixes. Language in Japan 2: 4-29.
16 宮岡大・黄,海萍(2023)「愛媛県方言談話資料 : 大洲市の場面設定データ（2023年11月公開版）」文化庁「各地方言収集緊急調査」方言談話資料（国立国語研究所学術情報リポジトリ）
17 高城隆一(2020)「鹿児島県霧島市隼人町方言の自他交替」『東京大学言語学論集』42: 114-149.
18 高城隆一(2022)「鹿児島県肝付町（内之浦）」セリックケナン・五十嵐陽介・木部暢子・青井隼人・大島一編『日本の消滅危機言語・方言の文法記述』国立国語研究所
19 Miyagawa, So (2025) RAG-Enhanced Neural Machine Translation of Ancient Egyptian Text: A Case Study of THOTH AI. In Proceedings of the 5th International Conference on Natural Language Processing for Digital Humanities, pages 33–40, Albuquerque, USA. Association for Computational Linguistics.
20 Igarashi, Ryo, and So Miyagawa (2024) Enhancing Neural Machine Translation for Ainu-Japanese: A Comprehensive Study on the Impact of Domain and Dialect Integration. In Proceedings of the 4th International Conference on Natural Language Processing for Digital Humanities, pages 413–422, Miami, USA. Association for Computational Linguistics.
21 Miyagawa, So (2024) Ainu–Japanese Bi-directional Neural Machine Translation: A Step Towards Linguistic Preservation of Ainu, An Under-Resourced Indigenous Language in Japan. Journal of Data Mining & Digital Humanities 29.
22 Miyagawa, So, Kanji Kato, Miho Zlazli, Salvatore Carlino, and Seira Machida (2023) Building Okinawan Lexicon Resource for Language Reclamation/Revitalization and Natural Language Processing Tasks such as Universal Dependencies Treebanking. In Proceedings of the Second Workshop on Resources and Representations for Under-Resourced Languages and Domains, 86–91, Tórshavn, the Faroe Islands. Association for Computational Linguistics.
23 ジスクマシュー（代表者）2019-2023 基盤B「多言語による日本語学用語辞典および日琉諸語の用例に対するグロス規範の作成」19H01265
24 ジスクマシュー (2021)「英訳から見えてくる日本語学用語の長所と短所」『日本語学』40 (2): 126-137.
25 Zisk, Matthew (2023) Glossing glosses: Methods for transcribing and glossing Japanese kundoku texts. In Cinato, Franck, et al. eds. Glossing Practice, Comparative Perspectives, 47-82, Lexington Books.
26 乙黒亮・田川拓海 (2024)『形態論の諸相 6つの現象と2つの理論』くろしお出版.
27 田川拓海 (2023)「分散形態論におけるゼロ形態とその削減」大関洋平・漆原朗子(編)『分散形態論の新展開』, 212～235, 開拓社.
28 田川拓海 (2019)「分散形態論と日本語の補充：存在動詞『いる』と『おる』の交替」岸本秀樹(編) 『レキシコンの現代理論とその応用』, 27-48, くろしお出版.
29 那須 昭夫, 今田 水穂, 文 昶允, 田川拓海 (2022)「接尾辞「-方」を含む派生名詞でのアクセント変異—平板化率にみる地域差と母方言からの干渉—」『音声研究』26 (1) : 1-12.
30 宮岡大 (2025)「日琉諸語方言研究グロスリスト」（https://doi.org/10.5281/zenodo.17068365）

３　人権の保護及び法令等の遵守への対応（公募要領参照）

本研究を遂行するに当たって、相手方の同意・協力を必要とする研究、個人情報の取扱いの配慮を必要とする研究、生命倫理・安全対策に対する取組を必要とする研究など指針・法令等（国際共同研究を行う国・地域の指針・法令等を含む）に基づく手続が必要な研究が含まれている場合、講じる対策と措置を、１頁以内で記述すること。
個人情報を伴うアンケート調査・インタビュー調査・行動調査（個人履歴・映像を含む）、提供を受けた試料の使用、ヒト遺伝子解析研究、遺伝子組換え実験、動物実験など、研究機関内外の倫理委員会等における承認手続が必要となる調査・研究・実験などが対象となる。
該当しない場合には、その旨記述すること。

本研究では方言データの提供にあたって相手方の同意を必要とし、また個人情報の取り扱いについて十分は配慮を要する。そこで、以下のような対策を講じる。

取得する話者の個人情報（氏名、生年、出身地、両親の出身地、外住歴）は、まずインフォームドコンセントを徹底し、同意書を作成の上、丁寧に調査内容とデータの保存法、公開の可否などを説明する。研究者と合意の上、署名して話者側、研究者側の双方で保存する。同意書のフォーマットや上記の流れについては研究代表者を含め、本研究に関わる全員が十分な知識と経験を有している。

収集した個人情報はメタデータとして厳正に管理し、同意書において公開可とする情報を除き、マスキングして保存する。メタデータはプロテクトをかけ、研究代表者が責任を持って電子的に保存する。

４　研究計画最終年度前年度応募を行う場合の記述事項（該当者は必ず記述すること（公募要領参照））

本研究の研究代表者が行っている、令和８(2026)年度が最終年度に当たる継続研究課題の当初研究計画、その研究によって得られた新たな知見等の研究成果を記述するとともに、当該研究の進展を踏まえ、本研究を前年度応募する理由（研究の展開状況、経費の必要性等）を１頁以内で記述すること。
該当しない場合は記述欄を削除することなく、空欄のまま提出すること。

研究種目名	課題番号	研究課題名	研究期間